

# Estimación de máxima verosimilitud

**Definición 23. (Estimación puntual)** Considere el estadístico  $\hat{\Theta}$  asociado a un parámetro desconocido  $\theta$  para muestras de tamaño  $n$ . Una estimación puntual de  $\theta$  (o simplemente estimación de  $\theta$ ) es un valor  $\hat{\theta}$  generado por  $\hat{\Theta}$  en una muestra aleatoria específica de tamaño  $n$ .


En este tipo de estimaciones el problema es que no se puede medir el error de estimación; sin embargo, cuanto mayor sea el tamaño de la muestra, se espera que mejor sea la estimación.

De acuerdo con lo estudiado en el primer capítulo, dada una muestra observada  $(x_1, x_2, \dots, x_n)$  de una muestra aleatoria  $M$  se tienen las siguientes estimaciones puntuales de los respectivos parámetros:

Parámetro	Estimador	Estimación puntual
$\mu$	$\bar{X}$	$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$
$\sigma^2$	$S^2$	$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}$
$\sigma$	$S$	$s = \sqrt{s^2}$
$p$	$\hat{P}$	$\hat{p} = \frac{b}{n}$ , $b$ es el número de éxitos en la muestra

Empíricamente se maneja que  $\bar{x}$  es una buena estimación de  $\mu$  si el tamaño de muestra  $n$  es mayor o igual a 30;  $s$  es una buena estimación de  $\sigma$  si  $n$  es mayor o igual a 30, y  $\hat{p}$  es una buena estimación de  $p$  si  $n\hat{p} \geq 5 \wedge n(1-\hat{p}) \geq 5$ . Estos son resultados empíricos producto de la observación de varias simulaciones, no son teoremas; por lo tanto, según lo que se quiera estimar, puede suceder que las reglas anteriores sean muy exigentes.

Por otro lado, suponga que se tiene una variable  $X_1$  asociada a una población 1 con media poblacional  $\mu_1$  y una variable  $X_2$  asociada a una población 2 con media poblacional  $\mu_2$ .



**Estimación Puntual**

Total  $N = 20$       Tamaño muestra  $n = 3$

$P = \frac{3}{20}$

$n_1 \rightarrow p_1 = \frac{1}{3}$

$n_2 \rightarrow p_2 = \frac{2}{3}$

$n_3 \rightarrow p_3 = 1$

$\frac{3}{3}$

La función de verosimilitud es la probabilidad de que una muestra aleatoria observada ocurra en función del parámetro desconocido.

Geovani usa  $\theta$  en vez de  $\theta$

$$L(\theta|x) = \prod_{i=1}^n f(x_i, \theta) \rightarrow \text{Distribución de probabilidad}$$

Parámetro

valores muestrales

Básicamente el producto de todas las evaluaciones muestrales

Pasos

1- Derivar

2- Igualar a 0 y despejar

La estimación de máxima verosimilitud consiste en maximizar la función de verosimilitud.

### Ejemplo

La distribución de densidad de la variable aleatoria  $X$  viene dada por

$$f(x) = \frac{k}{3} \left(\frac{x}{3}\right)^{k-1} \quad \text{para } 0 \leq x \leq 3 \quad \text{y } k \text{ constante.}$$

Dadas las observaciones  $x_1 = 0,3$   $x_2 = 0,1$   $x_3 = 0,9$  encuentre la estimación de máxima verosimilitud de  $k$ .

$$f(x) = \frac{k}{3} \left(\frac{x}{3}\right)^{k-1}$$

$$L(k|x) = \frac{k}{3} \cdot \left(\frac{0,3}{3}\right)^{k-1} \cdot \frac{k}{3} \cdot \left(\frac{0,1}{3}\right)^{k-1} \cdot \frac{k}{3} \cdot \left(\frac{0,9}{3}\right)^{k-1}$$

$$= \frac{k^3}{3^3} \left(\frac{0,3}{3} \cdot \frac{0,1}{3} \cdot \frac{0,9}{3}\right)^{k-1}$$

$$= \frac{k^3}{27} \left(\frac{1}{1000}\right)^{k-1} \quad \text{Como tiene expo, se usa log}$$

$$\ln(L(k|x)) = \ln\left(\frac{k^3}{27} \cdot \left(\frac{1}{1000}\right)^{k-1}\right)$$

Continúa abajo

$$\ln(a \cdot b) = \ln(a) + \ln(b)$$

$$\ln\left(\frac{a}{b}\right) = \ln(a) - \ln(b)$$

$$\ln(L(\pi|x)) = \ln\left(\frac{\pi^3}{27} \cdot \left(\frac{1}{1000}\right)^{\pi-1}\right)$$

$$= \ln\left(\frac{\pi^3}{27}\right) + \ln\left(\frac{1}{1000}\right)^{\pi-1}$$

$$\ln(\pi^3) - \ln(27) + (\pi-1) \ln\left(\frac{1}{1000}\right)$$

$$3 \ln(\pi) - \ln(27) + (\pi-1) \ln\left(\frac{1}{1000}\right)$$

Ahora derivando

$$\ln(L(\pi|x)) = 3 \ln(\pi) - \ln(27) + (\pi-1) \ln\left(\frac{1}{1000}\right)$$

$$\frac{1}{L(\pi|x)} \cdot L'(\pi|x) = 3 \cdot \frac{1}{\pi} - 0 + 1 \cdot \ln\left(\frac{1}{1000}\right)$$

$$\frac{L'(\pi|x)}{L(\pi|x)} = \frac{3}{\pi} + \ln\left(\frac{1}{1000}\right)$$

Igualar a 0

$$\frac{3}{\pi} + \ln\left(\frac{1}{1000}\right) = 0$$

$$\frac{3}{\pi} = -\ln\left(\frac{1}{1000}\right)$$

$$\boxed{\pi = -\frac{3}{\ln\left(\frac{1}{1000}\right)}}$$

## Ejemplo

Considere una muestra aleatoria  $X_1, X_2, X_3, \dots, X_n$ , donde  $X$  es una variable aleatoria con distribución de probabilidad  $f(x) = \frac{x e^{-\frac{x}{\omega}}}{\omega^2}$  con  $x, \omega > 0$ . Verifique que el estimador de máxima verosimilitud de  $\omega$  es  $\hat{\omega} = \frac{\bar{X}}{2}$ . (5 puntos)

$$L(x, \omega) = \prod_{i=1}^n \frac{x_i e^{-\frac{x_i}{\omega}}}{\omega^2}$$

Por ser

$x_1, x_2, \dots, x_n$

El estimador es el que se deriva, lo demás es constante

Ojo, si tengo  $\prod_{i=1}^n f_x(t)$  y aplico  $\ln$ ,  
pasa a ser una suma  $\sum_{i=1}^n \ln(f_x(t))$

Entonces

$$\ln(L(x, \omega)) =$$

$$= \sum_{i=1}^n \ln\left(\frac{x_i e^{-\frac{x_i}{\omega}}}{\omega^2}\right)$$

$$= \sum_{i=1}^n \ln(x_i) + \ln\left(e^{-\frac{x_i}{\omega}}\right) - \ln(\omega^2)$$

$$= \sum_{i=1}^n \ln(x_i) - \frac{x_i}{\omega} - 2 \ln(\omega)$$

Continúa abajo

$$\sum f(x) \pm g(x) = \sum f(x) \pm \sum g(x)$$

$$\sum_{i=1}^n \pi = n \pi$$

$n$

$$\sum_{i=1}^n \ln(x_i) - \frac{x_i}{w} - \ln(w^2)$$

Este no tiene  $i$  entonces es una constante

$$\sum_{i=1}^n \ln(x_i) - \frac{1}{w} \sum_{i=1}^n x_i - \sum_{i=1}^n 2 \ln(w)$$

$$\sum_{i=1}^n \ln(x_i) - \frac{1}{w} \sum_{i=1}^n x_i - 2n \ln(w)$$

Derivando

$$\frac{L'(x, w)}{L(x, w)} =$$

$$\sum_{i=1}^n \ln(x_i) - \frac{1}{w} \sum_{i=1}^n x_i - 2n \ln(w)$$

Como esto no tiene  $w$ , su derivada es 0

Se mantiene la constante y se deriva  $w$

$$-\frac{1}{w} \sum_{i=1}^n x_i - 2n \ln(w)$$

se deriva normal  
n constante

$$\frac{-1}{w} = \frac{1}{w^2}$$

$$\frac{1}{w^2} \sum_{i=1}^n x_i - \frac{2n}{w}$$

Finalmente, igualar a 0

$$\frac{1}{w^2} \sum_{i=1}^n x_i - \frac{2h}{w} = 0$$

$$\frac{1}{w^2} \sum_{i=1}^n x_i - \frac{2hw}{w \cdot w}$$

$$\frac{1}{w^2} \sum_{i=1}^n x_i - \frac{2hw}{w^2}$$

$$\frac{1}{w^2} \left( \sum_{i=1}^n x_i - 2hw \right) = 0$$

$$\sum_{i=1}^n x_i - 2hw = 0$$

$$\sum_{i=1}^n x_i = 2hw$$

$$w = \frac{\sum_{i=1}^n x_i}{2h} = \boxed{\frac{\bar{x}}{2}}$$

Parámetro	Estimador	Estimación puntual
$\mu$	$\bar{X}$	$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$

Determine el estimador de máxima verosimilitud para el parámetro  $\lambda$  de una variable aleatoria  $X \sim P(\lambda)$  en una muestra aleatoria  $X_1, X_2, \dots, X_n$ .

Utilice este resultado para encontrar el valor  $x_5$  de modo que  $\lambda = 4$ , en la muestra  $x_1 = 1$ ,  $x_2 = 2$ ,  $x_3 = 1$ ,  $x_4 = 3$  y  $x_5$ . (8 puntos)

$\bar{x} = \lambda$  en poisson

Entonces

$$x_1 + x_2 + x_3 + x_4 + x_5 = 7$$

don  $\sum x_i \rightarrow 5$

$$= \frac{1 + 2 + 1 + 3 + x_5}{5} = 4$$

$$= \frac{7 + x_5}{5} = 4$$

$$= 7 + x_5 = 20$$

$$= \boxed{x_5 = 13}$$

Se puede hacer por definicion

$$4 = \frac{7 + x_5}{5} \Rightarrow x_5 = 13$$

---

$$L(x, \lambda) = \frac{\lambda e^{-\lambda}}{1!} \cdot \frac{\lambda^2 e^{-\lambda}}{2!} \cdot \frac{\lambda e^{-\lambda}}{1!} \cdot \frac{\lambda^3 e^{-\lambda}}{3!} \cdot \frac{\lambda^{x_5} e^{-\lambda}}{x_5!} = \frac{\lambda^{7+x_5} e^{-5\lambda}}{12x_5!}$$
$$\Rightarrow \ln(L(x, \lambda)) = (7 + x_5) \ln \lambda - 5\lambda - \ln(12x_5!)$$
$$\Rightarrow \frac{L'(x, \lambda)}{L(x, \lambda)} = \frac{7 + x_5}{\lambda} - 5$$
$$L'(x, \lambda) = 0 \Rightarrow \frac{7 + x_5}{4} = 5$$